

Information Theory

 Cover, Thomas M. *Elements of information theory*. John Wiley & Sons, 1999.




Fig. 1 — Schematic diagram of a general communication system.

이상적인 channel은 transmitter로부터 receiver까지 오류 없이 정보가 전달되는 channel이지만, 일반적인 channel은 noise channel임

Probability

Event : 일어날 수 있는 어떤 사건, 확률 변수가 가질 수 있는 값, $X = a$

▼ 확률 변수가 주어짐 ⇔ 확률 변수를 알 ⇔ 확률 분포를 알

ex. 동전을 던졌을 때 나올 수 있는 면에 대한 확률 변수 X

확률 변수 $X \in \{\text{앞면}, \text{뒷면}\}$

확률 분포는 $P(X=\text{앞면})=1/2, P(X=\text{뒷면})=1/2$

결과로 도출될 수 있는 모든 event를 모은 집합이 sample space이고, ‘어떤 event가 얼마나 나올 수 있는가?’에 대한 확률이 주어졌을 때 event에 대한 변수가 확률 변수이고 이 확률 변수의 events에 대한 확률이 확률 분포를 이룸

⇒ 확률 변수를 다루는 것은 어떤 event의 확률을 다루는 것이 아니라 변수의 확률 분포를 다루는 것

확률 질량 함수(probability mass function) : 이산 확률 변수의 확률 분포에 따른 함수

▼ 확률 변수 X 를 사용한 함수 $f(X)$ 도 변수에 대한 확률 분포를 갖는 확률 변수임

확률 변수

사건 공간에서 가측 공간으로의 가측 함수

ex. $f(X) = \begin{cases} 1 & \text{if } X = \text{Head} \\ 0 & \text{if } X = \text{Tail} \end{cases}$ 이때, X 는 event를 나타내는 변수

확률 변수 $f(X)$ 의 평균 $\mathbb{E}[f(X)] := \sum P(X = x)f(X = x)$

Joint distribution

$P(X,Y)$: joint distribution

$P(X), P(Y)$: marginal distribution

→ joint distribution이 주어지면
marginal distribution을 구할 수 있으나
역은 성립하지 않음

$P(Y|X=x)$: conditional distribution

Y 는 R.V.이고, 조건부의 x 는 value

$X=2$ 인 행에 대한 확률은
 $X=2$ 일 때의 Y 에 대한 조건부 분포를 나타냄

▼ ex

$Y \setminus X$	0	1	2	$P(Y)$
0	1/4	1/8	1/8	1/2
1	1/4	0	1/4	1/2
$P(X)$	1/2	1/8	3/8	

$Y \setminus X$	x	$P(Y)$
y		
$P(X)$		

Information and Uncertainty

▼ Information : level of surprise

→ 낮은 확률 = 높은 entropy
얼마나 적은 확률을 가지고 있으며, 알게 되었을 때 얼마나 놀라움을 주는가

X : random variable, $X \in \mathcal{X} = \{x_1, \dots, x_n\}$

▼ The information of an event $X = x_i$ is defiend by $I(x_i) := \log \frac{1}{P(X=x_i)} = -\log p(x_i)$

정보는 $P(X = x_i)$ 에만 depend한다. 즉, $I(x_i) = I(p(x_i)) = -\log p(x_i)$

💡 왜 log를 사용하여 정보를 나타내는가?

정보는 다음을 만족함

1. 확률이 낮으면 정보가 많고, 확률이 높으면 정보가 적음

2. $0 \leq P(X = x_i) \leq 1$

$I(x_i) \geq 0 \quad \because 0 < p(x) \leq 1$

(확률이 0인 event는 $\mathcal{X}$ 에 속하지 않음)

3. Fundamental Axioms (axiomatic approach)

$I(p)$: information measure

a. $I(p) \geq 0$

b. $p = 1 \Rightarrow I(p) = 0$

c. For tow independent events $P(X = x_i), P(Y = y_i),$

$I(X = x_i, Y = y_j) = I(X = x_i) + I(Y = y_j)$

because, $P(X = x_i, Y = y_i) = P(X = x_i)(Y = y_i)$


4. The information measure $I(p)$ is continuous

log의 밑을 2로 사용하면 정보량의 비트 수를 표현할 수 있음

▼ 분포의 information = $\mathbb{E}[I(X)] = \sum_x P(X = x)I(X = x) = -\sum_x p(x) \log p(x)$

“확률 변수를 앎 ⇔ 확률 분포를 앎”이기 때문에 R.V.의 information을 아는 것은 분포의 information을 아는 것과 같음

분포에 대한 information은 각각의 $X = x_i$ 에 대한 information을 물어보는 것이 아니기 때문에, 모든 x 에 대한 information의 기댓값을 구하여 분포의 information을 정의함



Mutual information

▼ For two R.V. $X \leftarrow \{x_1, x_2, \dots, x_m\}, Y \leftarrow \{y_1, y_2, \dots, y_m\},$

(case 1) X, Y are independent

$Y = y_j$ 의 발생이 $X = x_i$ 에 대한
어떠한 정보도 제공하지 않음

(case 2)의 그림

(case 2) X, Y are fully dependent

$Y = y_j$ 의 발생이 $X = x_i$ 의 발생을 결정

→ 통신 과정에서 Y=y를 전송 받으면
실제로 보내진 값 X가 x였음을 보장할 수 있음

$Y \setminus X$	x	P(Y)
y	0 ... 0 1 0 ... 0	
P(X)		

▼ $I(X; Y)$: mutual information (average of mutual information $X = x_i, Y = y_j$) — for R.V.s

$I(X; Y) = \sum_{x,y} p(x, y)I(x, y)$

$I(x,y)$ 는 $X=x, Y=y$ 일 때의 상호 정보량을 나타냄

일반적으로 joint information을 정의한 기호가 없기 때문에
고정된 x_i, y_j 에 대한 mutual information 표기를 ;이 아닌 ,로 사용함

▼ $I(X; Y) := \sum_{x,y} p(x, y)[I(x) - I(x|y)] = \sum_{x,y} p(x, y) \log \frac{p(x,y)}{p(x)p(y)}$

(위 식의 첫 등식에 나오는 $p(x, y)$ 는 $x = x_i, y = y_j$ 에 대한 $p(x_i, y_j)$ 임.

$I(x_i; y_j) = I(x_i) - I(x_i|y_j))$ — for event

$Y=y$ 임을 알게 됨으로써 줄어드는 x에 대하여 모르는 정도(정보량)

상호 정보량이 높으면 Y를 알 때 X를 알 확률이 높아짐

$I(x) - I(x|y) = \log \frac{1}{p(x)} - \log \frac{1}{p(x|y)} = \log \frac{p(x|y)}{p(x)} = \log \frac{p(x,y)}{p(x)p(y)}$

$I(X; Y) = I(Y; X)$

▼ $I(X; Y) = H(X) - H(X|Y)$

$$\begin{aligned}
 \text{pf) } I(X; Y) &= \sum_{x,y} p(x,y) \log \frac{p(x,y)}{p(x)p(y)} \\
 &= \sum_{x,y} p(x,y) \log \frac{1}{p(x)} - \sum_{x,y} p(x,y) \log \frac{p(y)}{p(x,y)} \\
 &= \sum_x p(x) \log \frac{1}{p(x)} - \sum_{x,y} p(x,y) \log \frac{1}{p(x|y)} \\
 &= H(X) - H(X|Y)
 \end{aligned}$$

네 번째 등호 넘어갈 때 아래 참고

$$\begin{aligned}
 H(X|Y) &= \sum_y p(y) H(X|Y = y) \\
 &= \sum_y p(y) \sum_x p(x|y) \log \frac{1}{p(x|y)} \\
 &= \sum_{x,y} p(x|y)p(y) \log \frac{1}{p(x|y)} = \sum_{x,y} p(x,y) \log \frac{1}{p(x|y)}
 \end{aligned}$$

▼ 변형

$$H(X) = H(X|Y) + I(X; Y) \text{ ; X에 대한 불확실성은 Y를 알 때 X에 대하여 모르는 정도와 Y를 알 때 X를 아는 정도의 합}$$

좋은 채널 = 상호 정보량이 높은 채널

▼ Ex 1

- independent : $p(x|y) = p(x) \Rightarrow I(x; y) = 0$
- fully dependent : $p(x|y) = 1 \Rightarrow I(x; y) = I(x)$


▼ Ex 2 (binary symmetric channel)

p : error rate

(case 1)

X	0	1
P(X)	1	0

Y	0	1
P(Y)	1-p	p



(case 2)

X	0	1
P(X)	1/2	1/2

Y	0	1
P(Y)	1/2	1/2

FIGURE 1.3. Noiseless binary channel. $C = 1$ bit.




FIGURE 1.5. Binary symmetric channel.

$$\begin{aligned}
 P(Y = 0) &= P(Y = 0|X = 0)P(X = 0) + P(Y = 0|X = 1)P(X = 1) \\
 &= (1 - p)(1/2) + p(1/2) = 1/2
 \end{aligned}$$

$$\begin{aligned}
 P(Y = 1) &= P(Y = 1|X = 0)P(X = 0) + P(Y = 1|X = 1)P(X = 1) \\
 &= p(1/2) + (1 - p)(1/2) = 1/2
 \end{aligned}$$

$$I(X = 0; Y = 0) = \log \frac{p(x|y)}{p(x)} = \log \frac{p(y|x)}{p(y)} = \log \frac{1-p}{1/2} = \log 2(1 - p) = \log(1 - p)$$

$$I(X = 0; Y = 1) = \log \frac{p(x|y)}{p(x)} = \log \frac{p(y|x)}{p(y)} = \log \frac{p}{1/2} = \log 2p = \log p$$

→ $p \rightarrow 0$ 일 때 $\log p \rightarrow -\infty$; 개별 상호 정보량은 음수가 나오는 경우도 있으나, 평균을 구하면 0보다 큰 값으로 보정됨

Conditional Mutual Information

$$I(X; Y \mid Z) = H(X|Z) - H(X \mid Y, Z)$$

▼ Theorem (Chain rule for mutual information)

$$I(X_1, \dots, X_n; Y) = \sum_{i=1}^n I(X_i; Y \mid X_{i-1}, \dots, X_1)$$

$$\begin{aligned}
 \text{pf) } I(X_1, \dots, X_n; Y) &= H(X_1, \dots, X_n) - H(X_1, \dots, X_n \mid Y) \\
 &= \sum_{i=1}^n H(X_i \mid X_{i-1}, \dots, X_1) - \sum_{i=1}^n H(X_i \mid X_{i-1}, \dots, X_1, Y) \\
 &= \sum_{i=1}^n [H(X_i \mid X_{i-1}, \dots, X_1) - H(X_i \mid \textcolor{red}{Y}, X_{i-1}, \dots, X_1)] \\
 &= \sum_{i=1}^n H(X_i; Y \mid X_{i-1}, \dots, X_1)
 \end{aligned}$$

Entropy

The Shannon entropy of R.V. $X \sim p(x)$ is defined by

$$H(X) := - \sum_x p(x) \log p(x) \quad \text{ ; } \log \frac{1}{p(x)} \text{의 기대값(평균)}$$

▼ 확률 변수의 (확률 분포의) 평균 information

$$H(X) := \mathbb{E}[I(X)]$$

- 어떤 분포를 따르는 확률 변수를 표현할 수 있는 최소 비트 수
- 데이터를 최대로 압축 때의 크기 (바른 복원을 보장할 수 있어야 함)

▼ Example 1.1.2 (*x*의 확률이 *uniform*하지 않은 경우 *code word*의 길이가 줄어드는 상황)

Example 1.1.2 Suppose that we have a horse race with eight horses taking part. Assume that the probabilities of winning for the eight horses are $(\frac{1}{2}, \frac{1}{4}, \frac{1}{8}, \frac{1}{16}, \frac{1}{64}, \frac{1}{64}, \frac{1}{64}, \frac{1}{64})$. We can calculate the entropy of the horse race as

$$\begin{aligned} H(X) &= -\frac{1}{2} \log \frac{1}{2} - \frac{1}{4} \log \frac{1}{4} - \frac{1}{8} \log \frac{1}{8} - \frac{1}{16} \log \frac{1}{16} - 4 \frac{1}{64} \log \frac{1}{64} \\ &= 2 \text{ bits.} \end{aligned} \tag{1.3}$$

x_i	1	2	3	4	5	6	7	8
$p(x_i)$	1/2	1/4	1/8	1/16	1/64	1/64	1/64	1/64
code	0	10	110	1110	111100	111101	111110	111111

평균 코드 길이 = entropy ; $\mathbb{E}[\text{code len}] = \mathbb{E}[f(X)]$

▼ Example 1.1.3

X	0	1
$P(X)$	p	$1 - p$

$$H(X) = H(p)$$




FIGURE 2.1. $H(p)$ vs. p .

Joint entropy

R.V. $Z := (X, Y) \sim p(z) = p(x, y) := P[X = x \text{ and } Y = y]$

$$H(Z) = H(X, Y) = \sum_x \sum_y p(x, y) \log \frac{1}{p(x, y)} = \mathbb{E}_{x, y}[-\log(X, Y)]$$

Conditional entropy

$H(Y|X)$; $X = x_i$ 의 x_i 가 변화할 때 Y 의 엔트로피



Shannon entropy : 정보량의 평균

$$H(Y|X) := \sum P(X = x_i)H(Y|X = x_i)$$

Mutual entropy

$$\blacktriangledown H(X; Y) := \sum_x \sum_y p(x, y) \log \frac{p(x, y)}{p(x)p(y)}$$

Y=y임을 알게 됨으로써 줄어드는 x에 대하여 모르는 정도(정보량)

$$I(x) - I(x|y) = \log \frac{1}{p(x)} - \log \frac{1}{p(x|y)} = \log \frac{p(x|y)}{p(x)} = \log \frac{p(x, y)}{p(x)p(y)}$$

Theorem (Chain Rule)

$$H(X, Y) = H(Y) + H(X|Y)$$

joint dist (X,Y)의 불확실성

= Y에 대한 불확실성 + Y를 알 때 X에 대한 불확실성

▼ 증명

$$\begin{aligned} H(X, Y) &= - \sum_{x, y} \log p(x, y) \\ &= - \sum_{x, y} p(x, y) \log p(x)p(y|x) \\ &= - \sum_{x, y} p(x, y) \log p(x) - \sum_{x, y} p(x, y) \log p(y|x) \\ &= - \sum_x p(x) \log p(x) - \sum_{x, y} p(x, y) \log p(y|x) \\ &= H(X) + H(Y|X) \end{aligned}$$

Y \ X	x	P(Y)
y	$H(X, Y)$	$H(Y)$
P(X)		


▼ Corollary (Diagram about Entropy & M.I.)

$H(X, Y \mid Z) = H(X \mid Z) + H(X \mid Y, Z)$

$I(X; Y) = H(X) - H(X \mid Y)$
 $= I(Y; X) = H(Y) - H(Y \mid X)$

$H(X, Y) = H(X) + H(Y \mid X)$
 $= H(Y, X) = H(Y) + H(X \mid Y)$

$I(X; X) = H(X)$



Chain rule for entropy

$X_1, X_2, \dots, X_n$ are R.V.s $\sim p(x_1, \dots, x_n)$

$H(X_1, \dots, X_n) = \sum_{i=1}^n H(X_i \mid X_{i-1}, \dots, X_1)$

▼ pf 1

$H(X_1, X_2) = H(X_1) + H(X_2 \mid X_1)$

$H(X_1, X_2, X_3) = H(X_1) + H(X_2, X_3 \mid X_1)$
 $= H(X_1) + H(X_2 \mid X_1) + H(X_3 \mid X_2, X_1)$ (by corollary)

...

$H(X_1, \dots, X_n)$
 $= H(X_1) + H(X_2, \dots, X_n \mid X_1)$
 $= H(X_1) + H(X_2 \mid X_1) + H(X_3 \mid X_2, X_1) + \dots + H(X_n \mid X_{n-1}, \dots, X_1)$
 $= \sum_{i=1}^n H(X_i \mid X_{i-1}, \dots, X_1)$

▼ pf 2

$p(x_1, x_2) = p(x_1)p(x_2 \mid x_1)$

$p(x_1, x_2, x_3) = p(x_1, x_2)p(x_3 \mid x_1, x_2) = p(x_1)p(x_2 \mid x_1)p(x_3 \mid x_1, x_2)$

...

$p(x_1, x_2, \dots, x_n) = \prod_{i=1}^n p(x_i \mid x_{i-1}, \dots, x_1)$

Then,

$H(X_1, \dots, X_n) = - \sum_{x_1, \dots, x_n} p(x_1, \dots, x_n) \log p(x_1, \dots, x_n)$
 $= - \sum_{x_1, \dots, x_n} p(x_1, \dots, x_n) \log \prod_{i=1}^n p(x_i \mid x_{i-1}, \dots, x_1)$
 $= - \sum_{x_1, \dots, x_n} p(x_1, \dots, x_n) \sum_{i=1}^n \log p(x_i \mid x_{i-1}, \dots, x_1)$
 $= - \sum_{i=1}^n \sum_{x_1, \dots, x_n} p(x_1, \dots, x_n) \log p(x_i \mid x_{i-1}, \dots, x_1)$
 $= - \sum_{i=1}^n \sum_{x_1, \dots, x_i} p(x_1, \dots, x_i) \log p(x_i \mid x_{i-1}, \dots, x_1)$
 $= - \sum_{i=1}^n H(X_i \mid X_{i-1}, \dots, X_1)$

Relative entropy

▼ $D(p \parallel q) = \sum_i p(x_i) \log \frac{p(x_i)}{q(x_i)}$ — p와 q의 차이

$\neq D(q \parallel p)$ (in general)


- A measure of the distance between two distributions p and q
- p 가 중심이 되어 바라볼 때 q 의 분포가 얼마나 가까운가

R.V. distribution

- $X \sim p \wedge \widetilde{X} \sim q$
- $\chi = \{x_1, \dots, x_n\}$ (the same sample space)
 $\Rightarrow$ 서로 다른 sample space에서 정의된 변수는
비교 대상이 될 수 없음

$q(x_i) := P(\widetilde{X} = x_i)$

$p(x_i) := P(X = x_i)$



▼ $\sum p(x) \log \frac{1}{p(x)} + \sum p(x) \log \frac{p(x)}{q(x)} = \sum p(x) \log \frac{1}{q(x)}$

p : true distribution (unknown) $\wedge$ q : approximation (guessing) of p

If we can construct a "good code" for $X \sim p$, then the average cod length = $H(p)$

Instead, we use (of mis-use) a code for $X \sim q$,
then the average code length = $\sum p(x) \log \frac{1}{q(x)} > H(p)$

⇒ We need $H(p) + D(p \parallel q)$ bits on the average.

현실에서 code word를 부여하여 코딩할 때 필요한 평균 비트 수는
최소 요구 비트 수 + 잘못 부여함에 의한 추가 비트 수

▼ ex. Code word

x_i	1	2	3	4	5	6	7	8
$p(x_i)$	1/2	1/4	1/8	1/16	1/64	1/64	1/64	1/64
code	0	10	110	1110	111100	111101	111110	111111

sequence of R.V.s: $X_1, X_2, \dots, X_n$ where $X_i \sim P(X)$

⇒ 변수의 절반은 1, 나머지 절반은 2, ... 같은 방식으로 값이 나올 것을 예상할 수 있음

주어진 상황에서 $H(X) = -\sum p(x) \log p(x)$ 이고, 엔트로피는 event에 대한 information의 평균이며 동시에 최적화된 (minimized) code length의 평균임

결국 information이자 code length인 $\log \frac{1}{p(x)}$ 가 변수를 뽑을 때마다 계산됨

⇒ $X_1, \dots, X_n$ 중 절반은 code length가 1, 나머지 절반은 2, ... 가 됨

$H(X) = 2$ 이므로 X_1 부터 X_n 까지 표현하기 위한 비트는 평균적으로 $2 \cdot n$ bits가 필요함

R.V.의 sequence를 가지고 있으면 이 sequence를 어느 정도의 길이로 표현할 수 있는가는 분포에 의해 정해지고, 최적화된 code length인 엔트로피를 가지고 있는 것이 Shannon's entropy 값임

▼ 설명

known $X_1, X_2, \dots, X_n \sim p(x) \Rightarrow \log \frac{1}{p(x)}$; code length $\Rightarrow \sum p(x) \log 1/p(x)$

확률 분포를 알면 최적화된 code word의 길이를 구할 수 있음

반대로 fixed $p(x)$ 를 모르는 경우, $q(x)$ 로써 code word의 길이를 guessing하는 과정이 필요함

$$q(x) \Rightarrow \log \frac{1}{q(x)}$$

$$\Rightarrow \text{최적화 code word 길이} = \text{실제 나올 확률} \times \text{부여한 코드 길이} \Rightarrow \sum q(x) \log \frac{1}{q(x)}$$

$p(x)$ 를 모르는 채 $X_1, X_2, \dots, X_n$ 을 뽑아서 average length를 계산할 수 있음

실제로 구해서 계산하게 되는 값은 $\sum p(x) \log \frac{1}{p(x)}$ 이므로 두 값의 차이를 알 수 있음

$$D(p \parallel q) := \sum p(x) \log \frac{1}{q(x)} - \sum p(x) \log \frac{1}{p(x)} = \sum p(x) \log \frac{p(x)}{q(x)}$$

▼ Mutual information과의 관계

Mutual inforamtion

$$I(x_i; y_j) = I(x_i) - I(x_i|y_j) = \log \frac{1}{p(x_i)} - \log \frac{1}{p(x_i|y_j)} = \log \frac{p(x_i, y_j)}{p(x_i)p(y_j)}$$

$$\begin{aligned} I(X; Y) &= \sum p(x_i, y_j) I(x_i; y_j) \\ &= \sum p(x_i, y_j) \log \frac{p(x_i, y_j)}{p(x_i)p(y_j)} = D(p(x, y) \parallel p(x)p(y)) \text{ --- joint || product} \end{aligned}$$

$$\therefore I(X; Y) = 0 \Leftrightarrow p(x, y) = p(x)p(y) \text{ for } \forall x, y \text{ --- independent}$$

⇒ joint 분포와 product의 분포의 차이가 0



$$0 \log \frac{0}{0} \rightarrow 0 \quad 0 \log \frac{0}{g} \rightarrow 0 \quad p \log \frac{p}{0} \rightarrow \infty$$

define $p(x), q(x)$ for $\exists x \in \chi$ s.t. $p(x) > 0, q(X) = 0$
then $D(p \parallel q) = \infty$

▼ ex. $D(p \parallel q) \neq D(q \parallel p)$

$$\chi = \{0, 1\}$$

$$\begin{aligned} H(p) &= -\sum p(x) \log p(x) \\ &= -(1-r) \log(1-r) \\ &\quad -r \log r \end{aligned}$$

$$H(p) \leftarrow$$

$$H(q) \leftarrow$$

x	0	1
p(x)	1-r	r
q(x)	1-s	s

$$H(q) = -(1-s) \log(1-s) = s \log s$$

$$\text{For } r = \frac{1}{2}, s = \frac{1}{4},$$

$$D(p \parallel q) = \sum p(X) \log \frac{p(x)}{q(x)} = \frac{1}{2} \log \frac{1/2}{3/4} + \frac{1}{2} \log \frac{1/2}{1/4} \approx 0.2075$$

$$\text{and } D(q \parallel p) = \frac{3}{4} \log \frac{3/4}{1/2} + \frac{1}{4} \log \frac{1/4}{1/2} \approx 0.1887$$

Jensen's inequality

convex 또는 concave를 판단하기 위해서는 조건을 만족하도록 구간을 설정해 주어야 함

Def: Convex

$f : (a, b) \rightarrow \mathbb{R}$ is convex if for every $x_1, x_2 \in (a, b)$,
 $f(\lambda x_1 + (1 - \lambda)x_2) \leq \lambda f(x_1) + (1 - \lambda)f(x_2)$ where $0 \leq \forall \lambda \leq 1$
(구간 내 x=a일 때, 곡선 위 point $\leq$ 구간 내 x=a일 때, 직선 위의 point)



convex

Def: Concave

$f : (a, b) \rightarrow \mathbb{R}$ is concave if $-f$ is convex




concave

▼ Theorem

$f \in C^2$ (f', f'' exist and are continuous) and $f''(x) \geq 0$ on (a, b) , then f is convex

pf: $f(x) = f(x_0) + f'(x_0)(x - x_0) + (f''(x^*)/2)(x - x_0)^2$, $x^* \in [x_0, x]$
 $(f''(x^*)/2)(x - x_0)^2 \geq 0$ | $y = ax^2 + bx + c, a > 0$ 꼴로 convex

x_1, x_2 : arbitrarily given points
Let $x_0 := \lambda x_1 + (1 - \lambda)x_2$ ($0 \leq \lambda \leq 1$)
 $f(x_1) = f(x_0) + f'(x_0)(x_1 - x_0) + (f''(x_1^*)/2)(x_1 - x_0)^2$
 $(x_1^*$ lines between x_0, x_1)



$f(x_2) = f(x_0) + f'(x_0)(x_2 - x_0) + (f''(x_2^*)/2)(x_2 - x_0)^2$
 $(x_2^*$ lines between x_0, x_1)

Since $f''(x_1^*) \geq 0, f''(x_2^*) \geq 0$,
1. $f(x_1) \geq f(x_0) + f'(x_0)(x_1 - x_0)$
2. $f(x_2) \geq f(x_0) + f'(x_0)(x_2 - x_0)$

$$\begin{aligned} &\lambda f(x_1) + (1 - \lambda)f(x_2) \\ &\geq \lambda f(x_0) + \lambda f'(x_0)(x_1 - x_0) + (1 - \lambda)f(x_0) + (1 - \lambda)f'(x_0)(x_2 - x_0) \\ &= f(x_0) + f'(x_0)[\lambda x_1 + (1 - \lambda)x_2 - x_0] \\ &= f(x_0) + f'(x_0)[\lambda x_1 + (1 - \lambda)x_2 - x_0] \\ &= f(x_0) + f'(x_0)[x_0 - x_0] = f(x_0) \\ &= f(\lambda x_1 + (1 - \lambda)x_2) \end{aligned}$$

$\therefore f$ is convex

▼ Thm: Jensen's inequality

f : convex and X : R.V. then $\mathbb{E}[f(X)] \geq f(\mathbb{E}[X])$

pf: We use mathematical induction.

Let $\chi_2 = \{x_1, x_2\}, \dots, \chi_k = \{x_1, x_2, \dots, x_n\}$ where $|\chi_i| = i$ for all $2 \leq i \leq k$

case 1) $\chi = \{x_1, x_2\}$

$$\begin{aligned} \mathbb{E}[f(X)] &= p_1 f(x_1) + p_2 f(x_2) \\ &= p_1 f(x_1) + (1 - p_1) f(x_2) \\ &\geq f(p_1 x_1 + (1 - p_1) x_2) \text{ since } f \text{ is convex} \\ &= f(\mathbb{E}[X]) \end{aligned}$$

x	x_1	x_2
$p(x)$	p_1	p_2

case 2) Suppose that Theorem is true for $|\chi| \leq k - 1$

$X \sim \{ \chi := \{x_1, \dots, x_k\} \text{ and } p_i := P[X = x_i] \ (i = 1, \dots, k) \}$ are given.

Define a distribution X' with $\chi_{k-1} := \{x_1, \dots, x_{k-1}\}$
where $p'_i := P(X = x_i) = \frac{p_i}{1 - p_k} \ (i = 1, \dots, k - 1)$

$$\begin{aligned} \mathbb{E}[f(X)] &= \sum p_i f(x_i) = p_k f(x_k) + \sum_{i=1}^{k-1} p_i f(x_i) \\ &= p_k f(x_k) + (1 - p_k) \sum_{i=1}^{k-1} \frac{p_i}{1 - p_k} f(x_i) \\ &= p_k f(x_k) + (1 - p_k) \sum_{i=1}^{k-1} p'_i f(x_i) \\ &= p_k f(x_k) + (1 - p_k) \mathbb{E}[f(X')] \\ &\geq p_k f(x_k) + (1 - p_k) f\left(\sum_{i=1}^{k-1} p'_i x_i\right) \text{ for } |\chi| \leq k - 1 \\ &\geq f\left(p_k x_k + (1 - p_k) \sum_{i=1}^{k-1} p'_i x_i\right) \text{ by } f : \text{convex} \end{aligned}$$

$$\begin{aligned}
&= f\left(p_k x_k + (1 - p_k) \sum_{i=1}^{k-1} \frac{p_i}{1 - p_k} x_i\right) \\
&= f\left(\sum_{i=1}^k p_i x_i\right) \\
&= f(\mathbb{E}[X])
\end{aligned}$$

▼ Theorem: Information inequality

$$D(p \parallel q) \geq 0 \quad , \quad I(X; Y) \geq 0 \quad , \quad H(X) \leq \log |\chi|$$

$p(x), q(x)$ are p.m.f. (probability mass function) on $x \in \chi$

$$1. D(p \parallel q) \geq 0 \quad (\text{equality holds} \iff p(x) \equiv q(x))$$

▼ pf

$\text{supp}(f)$: support of f

$\text{supp}(f) := \{x | f(x) > 0\} = \overline{\{x | f(x) > 0\}}$ where x is discrete

Let $A := \{x | p(x) > 0\}$ (i.e. $A := \text{supp}(p)$)

$$\begin{aligned}
-D(p \parallel q) &= -\sum_{x \in \chi} p(x) \log \frac{p(x)}{q(x)} = -\sum_{x \in A} p(x) \log \frac{p(x)}{q(x)} \\
&= \sum_{x \in A} p(x) \log \frac{q(x)}{p(x)} \quad \dots \quad \mathbb{E} \left[\log \frac{q(X)}{p(X)} \right] \\
&\leq \log \left[\sum_{x \in A} p(x) \frac{q(x)}{p(x)} \right] \text{ by Jensen's inequality} \\
&= \log \left[\sum_{x \in A} q(x) \right] \\
&\leq \log \left[\sum_{x \in \chi} q(x) \right] = \log 1 = 0
\end{aligned}$$

$$\therefore D(p \parallel q) \geq 0$$

$$2. I(X; Y) \geq 0 \quad (\text{equality holds} \iff X, Y \text{ are independent})$$

▼ pf

$$I(X; Y) = D(p(x, y) \parallel p(x)q(y)) \geq 0$$

$$3. X: \text{R.V. } x \in \chi, H(X) \leq \log |\chi| \quad (\text{entropy는 distribution이 uniform일 때 최대})$$

▼ pf

Let $u(x) := \frac{1}{|\chi|}$ (constant function on χ)

$u(x)$ is uniform p.m.f. over χ .

Then for any R.V. $X \sim P$

$$\begin{aligned}
D(p \parallel q) &= \sum p(x) \log \frac{p(x)}{u(x)} \\
&= \sum p(x) \log |\chi| + \sum p(x) \log p(x) \\
&= \log |\chi| - \sum p(x) \log \frac{1}{p(x)} \quad \text{since } \log |\chi| \text{ is constant and } \sum p(x) = 1 \\
&= \log |\chi| - H(X) \geq 0
\end{aligned}$$

$$\therefore H(X) \leq \log |\chi|$$

$\Rightarrow$ entropy of X is smaller than Entropy of uniform distribution

▼ Theorem: Conditioning reduces entropy

$$H(X|Y) \leq H(X)$$

$$\text{pf: } 0 \leq I(X; Y) = H(X) - H(X|Y)$$

$$\therefore H(X) \geq H(X|Y)$$

$$\text{ex. } H(X) = H\left(\frac{1}{8}, \frac{7}{8}\right) \text{ or}$$

$$= H(p) \text{ where } p = \frac{1}{8}, q = 1 - p$$

$$H(X|Y = 2) = H\left(\frac{1}{2}, \frac{1}{2}\right) = 1$$

$$\therefore H(X) \ll H(X|Y = 2)$$

$\Rightarrow$ 정리에 모순인 것처럼 보이지만,

정리는 average에 대한 내용이고

예제는 single term $Y = 2$ 라는

특정 상황에 대한 결과임

$Y \setminus X$	1	2	$P(Y)$
1	0	3/4	3/4
2	1/8	1/8	1/4
$P(X)$	1/8	7/8	

▼ Theorem: independence bound

$$H(X_1, \dots, X_n) \leq \sum_{i=1}^n H(X_i) \quad (\text{equality} \Leftrightarrow \text{independence})$$

pf: By the Chain rule,

$$\begin{aligned}
H(X_1, \dots, X_n) &= \sum_{i=1}^n H(X_i | X_{i-1}, \dots, X_1) \\
&\leq \sum_{i=1}^n H(X_i) \text{ by previous theorems}
\end{aligned}$$

Log-sum inequality and its Applications

Theorem: Log-sum inequality

▼ For non-negative numbers $a_1, \dots, a_n$ and $b_1, \dots, b_n$,


$$\sum_{i=1}^n a_i \left(\log \frac{a_i}{b_i} \right) \geq \left(\sum_{i=1}^n a_i \right) \cdot \log \left(\frac{\sum_{i=1}^n a_i}{\sum_{i=1}^n b_i} \right) \quad (\text{equality} \Leftrightarrow \frac{a_i}{b_i} \text{ is constant})$$

pf: case 1) For $a_i \geq 0, b_i > 0$.

Let $f(t) := t \log t$, then $f(t)$ is convex.



$t \times a > t$ as $t \rightarrow \infty$ where $a > 1$



$$\text{Since } (\log t)' = \left(\frac{\log_e t}{\log_e 2} \right)' = \frac{1}{\log_e 2} \cdot \frac{1}{t},$$

$$f'(t) = \log t + \log e$$

$$f''(t) = \frac{1}{\log_e 2} \cdot \frac{1}{t} = \frac{\log e}{t} > \frac{1}{t} > 0$$

$$\therefore f''(t) > 0 \Rightarrow f \text{ is convex}$$

By Jensen's inequality $\mathbb{E}[f(X)] \geq f(\mathbb{E}[X])$ for convex f ,

$$\sum \alpha_i f(t_i) \geq f\left(\sum \alpha_i t_i\right)$$

for $X \leftarrow t_i, P_i \leftarrow \alpha_i$ where $\sum \alpha_i = \sum p_i = 1, \alpha_i \geq 0, p_i \geq 0$

Set $\alpha_i = \frac{b_i}{\sum_j b_j}$ because we need to property $\sum_i \alpha_i = \sum_i \frac{b_i}{\sum_j b_j} = \frac{1}{\sum_j b_j} (\sum_i b_i) = 1$.

set $t_i = \frac{a_i}{b_i}$

$$\begin{aligned} \text{Then we obtain } \sum_i \alpha_i f(t_i) &= \sum_i \frac{b_i}{\sum_j b_j} f\left(\frac{a_i}{b_i}\right) = \sum_i \frac{b_i}{\sum_j b_j} \frac{a_i}{b_i} \log \frac{a_i}{b_i} \\ &= \sum_i \frac{a_i}{\sum_j b_j} \log \frac{a_i}{b_i} = \frac{1}{\sum_j b_j} \sum_i a_i \log \frac{a_i}{b_i} \\ &\geq f\left(\sum_i \alpha_i t_i\right) \quad \text{by Jensen's inequality} \\ &= \left[\sum_i \left(\frac{b_i}{\sum_j b_j} \right) \frac{a_i}{b_i} \right] \log \left[\sum_i \left(\frac{b_i}{\sum_j b_j} \right) \frac{a_i}{b_i} \right] \\ &= \frac{1}{\sum_j b_j} \sum_i a_i \log \left(\frac{1}{\sum_j b_j} \sum_i a_i \right) \end{aligned}$$

In this inequality, $\frac{1}{\sum_j b_j} \sum_i a_i \log \frac{a_i}{b_i} \geq \frac{1}{\sum_j b_j} \sum_i a_i \log \left(\frac{1}{\sum_j b_j} \sum_i a_i \right)$

$$\therefore \sum_i a_i \log \frac{a_i}{b_i} \geq \sum_i a_i \log \left(\frac{\sum_i a_i}{\sum_i b_i} \right)$$

Applying Log-sum inequality

▼ $D(p \parallel q) \geq 0$ where p, q are p.m.f.

$$\text{Relative entropy } D(p \parallel q) := \sum_x p(x) \log \frac{p(x)}{q(x)} \geq \sum_x p(x) \log \frac{\sum_x p(x)}{\sum_x q(x)} = \sum_x p(x) \log 1 = 0$$

$$\therefore D(p \parallel q) \geq 0 \quad (\text{equality} \Leftrightarrow \frac{p(x)}{q(x)} = 1 \text{ for all } x)$$

▼ **Thm: Convexity of relative entropy**

$$D(\lambda p_1 + (1 - \lambda)p_2 \parallel \lambda q_1 + (1 - \lambda)q_2) \leq \lambda D(p_1 \parallel q_1) + (1 - \lambda)D(p_2 \parallel q_2)$$

$D(p \parallel q)$ is convex in the pair (p, q) where p, q are p.m.f.

i.e. If $(p_1, q_1), (p_2, q_2)$ are two pairs of p.m.f. and $0 \leq \lambda \leq 1$,

then $D(\lambda p_1 + (1 - \lambda)p_2 \parallel \lambda q_1 + (1 - \lambda)q_2) \leq \lambda D(p_1 \parallel q_1) + (1 - \lambda)D(p_2 \parallel q_2)$

pf: First, we check $\lambda p_1 + (1 - \lambda)p_2$ and $\lambda q_1 + (1 - \lambda)q_2$ are p.m.f.

It's trivial!

Next, $D(\lambda p_1 + (1 - \lambda)p_2 \parallel \lambda q_1 + (1 - \lambda)q_2)$

$$\begin{aligned} &:= \sum_x [\lambda p_1(x) + (1 - \lambda)p_2(x)] \log \frac{\lambda p_1(x) + (1 - \lambda)p_2(x)}{\lambda q_1(x) + (1 - \lambda)q_2(x)} \\ &\leq \sum_x \left[\sum_i \{ \lambda p_1 + (1 - \lambda)p_2 \} \log \frac{\lambda p_1 + (1 - \lambda)p_2}{\lambda q_1 + (1 - \lambda)q_2} \right] \\ &= \sum_x \left[\lambda p_1(x) \log \frac{\lambda p_1(x)}{\lambda q_1(x)} + (1 - \lambda)p_2(x) \log \frac{(1 - \lambda)p_2(x)}{(1 - \lambda)q_2(x)} \right] \\ &= \lambda \sum_x p_1(x) \log \frac{p_1(x)}{q_1(x)} + (1 - \lambda) \sum_x p_2(x) \log \frac{p_2(x)}{q_2(x)} \\ &= \lambda D(p_1 \parallel q_1) + (1 - \lambda)D(p_2 \parallel q_2) \end{aligned}$$

즉, 두 p.m.f.를 combination한 뒤 relative entropy는 각각의 relative entropy의 평균보다 작거나 같음

▼ Thm. Concavity of entropy

$H(p)$ is a concave function of p.m.f. p

pf 1: Let $p(x)$ is p.m.f., $x \in \chi = \{x_1, \dots, x_n\}$ with $|\chi| = n$

and $u(x) := \frac{1}{|\chi|}$ is uniform distribution

$H(p) = \log |\chi| - D(p \parallel u)$

💡 $D(p \parallel u) = \sum p(x) \log \frac{p(x)}{u(x)} = \sum p(x) \log \frac{1}{u(x)} - \sum p(x) \log \frac{1}{p(x)}$

Since $\log \frac{1}{u(x)} = \log |\chi|$ is constant, $D(p \parallel u) = \log |\chi| - H(p)$.

Thus $D(p \parallel u)$ is convex.

$\Rightarrow -D(p \parallel u)$ is concave

$H(p) = \log |\chi| - D(p \parallel u)$

$\therefore H(p)$ is concave

pf 2:

Channel Capacity

- 한번에 (일정 시간 내에) 최대로 전송할 수 있는 데이터



Communication channel
output이 확률적으로 input에 의존하는 시스템

▼ Ex (noisy four-symbol channel)

error rate $p = 1/2$

(case 1) $P(X = x)$ 가 uniform한 경우

X \ Y	1	2	3	4	P(X)
1	1/8	1/8	0	0	1/4
2	0	1/8	1/8	0	1/4
3	0	0	1/8	1/8	1/4
4	1/8	0	0	1/8	1/4
P(Y)	1/4	1/4	1/4	1/4	

Y를 받았을 때 X를 하나로 결정할 수 없음

$\rightarrow$ decoding 실패. $I(X; Y) \neq 1$

(case 2) $P(X = x)$ 가 uniform하지 않은 경우

X \ Y	1	2	3	4	P(X)
1	1/4	1/4	0	0	1/2
2	0	0	0	0	0
3	0	0	1/4	1/4	1/2
4	0	0	0	0	0
P(Y)	1/4	1/4	1/4	1/4	

noisy n-symbol channel




FIGURE 1.4. Noisy channel.

Y를 받으면 X를 결정할 수 있음

$\rightarrow$ decoding 성공. $I(X; Y) = 1$

4개의 정보를 전할 수 있는
2비트 채널을 가지고 있지만,

실제로는 1과 3 두 정보만
주고받는 1비트 채널로 사용함

$\rightarrow$ 채널 용량 $C = 1$ bit

더 좋은 방법이 있다면 C 수정

▼ $C := \max I(X; Y)$

The capacity is the maximum tate at which we can send information over the channel


채널의 기본적인 설정(입력 가능한 값들의 범위, error rate 등)은 코딩을 통해 바꿀 수 없음

코딩으로 변경 가능한 값은 $p(x)$

이를 조절하여 가장 큰 C 를 얻는 distribution으로 채널을 구성해야 효율이 가장 좋음

Data Processing inequality

Data flow



▼ Def: Markov Chain

X, Y, Z : R.V.s

$X \rightarrow Y \rightarrow Z$ (i.e. Markov chain) $\Leftrightarrow p(x, y, z) = p(x)p(y|x)p(z|y)$

and we also can denote as $X \longleftrightarrow Y \longleftrightarrow Z$



For $X_1, X_2, \dots, X_n$,

$X_1 \rightarrow X_2 \rightarrow \dots \rightarrow X_{n-1} \rightarrow X_n \rightarrow \dots$ is Markov chain when

$$P(X_n | X_{n-1}, \dots, X_1) = P(X_n | X_{n-1})$$

Def $\Leftrightarrow Z$ depends only on Y — (1)

$\Leftrightarrow Z$ is conditionally independent of X given Y — (2)

$$\text{i.e. } P(X, Z | Y) = P(X | Y)P(Z | Y)$$



Conditional probability

$$p(x, y) = p(x)p(y|x)$$

$$p(x, y, z) = p(x)p(y, z | x) = p(x)p(y|z)p(z | y, x)$$

...

$$p(x_1, x_2, \dots, x_n) = \prod_{i=1}^n p(x_i | x_{i-1}, \dots, x_1)$$

(1) For Markov chain $X \rightarrow Y \rightarrow Z$,

we need to show $p(x, y, z) = p(x)p(y|x)p(z | y, x) = p(x)p(y|x)p(z|y)$

By the definition, $p(z | y, x) = p(z|y)$ is trivial.



Z depends on X only through Y

즉, X 의 변화는 Y 를 통해서만 Z 에 반영됨

$\Leftrightarrow X$ 와 Z 가 depend하지만, Y 를 통해서만 depend하므로 Y 에만 depend하 보임

$\Leftrightarrow Z$ 가 X 로부터 depend하는 정도가 이미 Y 에 반영되어 있음

$$\text{Thus, } p(x, y, z) = p(x)p(y|x)p(z|y)$$

(2) Given Y ,

$$p(x, z | y) = p(x, y, z)/p(y) \text{ and by the property of Markov chain,}$$

$$= [p(x)p(y|x)p(z|y)]/p(y) = [p(x, y)/p(y)]p(z|y) = p(x|y)p(z|y)$$

Therefore, X, Z are independent given Y

By (1), (2), $X \rightarrow Y \rightarrow Z \iff X, Z$ are independent given Y

and it also can be represented as Z, X are independent given Y

then, $\iff Z \rightarrow Y \rightarrow X$ holds.

We may write $X \longleftrightarrow Y \longleftrightarrow Z$

Then if $Z = f(Y)$, $X \rightarrow Y \rightarrow f(Y)$?

직관적으로 생각할 때, Z 는 Y 가 결정되는 순간 같이 결정됨

i.e., Y determines Z completely.

It means Z depends only Y and is the definition of Markov chain.

So, this chain is holds.



R.V.s X, Y, Z 가 다음 중 하나라도 만족하면 Markov chain임

- $P(Z|Y) = P(Z | Y, X)$
- $P(X, Y, Z) = P(X)P(Y|X)P(Z|Y)$
- $P(Z|Y)P(X|Y) = P(X, Z | Y)$

$$X \xrightarrow[\text{channel 1}]{BSC} Y \xrightarrow[\text{channel 2}]{BSC} Z,$$

error rate of channel1 = p_1 , error rate of channel2 = p_2

BSC channel 1

Input data

X	0	1
$P(X)$	3/4	1/4

given $X = 0$

Y	0	1
$P(Y X = 0)$	$1 - p_1$	p_1

given $X = 1$

Y	0	1
$P(Y X = 1)$	p_1	$1 - p_1$

Joint distribution

$X \setminus Y$	0	1	$P(X)$
0	$\frac{3}{4}(1 - p_1)$	$\frac{3}{4}p_1$	3/4
1	$\frac{1}{4}p_1$	$\frac{1}{4}(1 - p_1)$	1/4
$P(Y)$	$\frac{3}{4} - \frac{1}{2}p_1$	$\frac{1}{4} - \frac{1}{2}p_1$	

Check: $P(X|Y)$

given Y (빈 칸 채우기)

given $Y = 0$	Y	0	1
	$P(X Y = 0)$		
given $Y = 1$	Y	0	1
	$P(X Y = 1)$		

$Z = f(Y) := 2Y - 1$ 라면

Joint distribution	$Y \setminus Z$	-1	1	$P(Y)$
$p_1 = 1/4$ 일 때 Y 의	0	5/8	0	5/8
input data	1	0	3/8	3/8
	$P(Z)$	5/8	3/8	

$$P(Y = 0) = 5/8$$
$$P(Y = 1) = 3/8$$

Y 의 분포를 알면 Z 의 분포가 fix됨
(X 의 분포를 모르고 Y 분포만 알아도 고정됨, 개입할 여지가 없어짐)

Theorem: Data Processing Inequality

$\blacktriangledown X \rightarrow Y \rightarrow Z \implies I(X; Y) \geq I(X; Z)$



Probability

$$p(x_1, \dots, x_n) = \prod_{i=1}^n p(x_i | x_{i-1}, \dots, x_1)$$

Entropy

$$H(x_1, \dots, x_n) = \sum_{i=1}^n H(x_i | x_{i-1}, \dots, x_1)$$
$$= H(x_1) + H(x_2|x_1) + H(x_3 | x_2, x_1) + \dots$$

Mutual information

$$I(X; Y) = H(X) - H(X|Y)$$
$$I(X_1, \dots, X_n ; Y) = \sum_{i=1}^n I(X_i; Y | X_{i-1}, \dots, X_1)$$

pf: Since $I(X; Y, Z) = I(Y, Z ; X) = I(Z, Y ; X)$
$$= I(Z; X) + I(Y; X | Z) = I(X; Z) + I(X; Y | Z)$$
$$= I(X; Z, Y) = I(X; Y) + I(X; Z | Y),$$
$$I(X; Z) + I(X; Y | Z) = I(X; Y) + I(X; Z | Y).$$
$$I(X; Z | Y) = 0 \text{ by property of Markov Chain}$$

- X, Z are conditionally independent given $Y \implies I(X; Z | Y) = 0$

$$I(X; Y) = I(X; Z) + I(X; Y | Z) \geq I(X; Z) \qquad \because I(A; B) \geq 0$$



직관적으로 생각해볼 때, X 로부터 Y 를 아는 것이 X 로부터 Z 를 아는 것보다 쉬움 (알 수 있는 정보가 더 많음). 이때 등호가 성립한다는 것은 Y 를 거쳐 Z 에서 X 가 영향을 미치는 정도에 손실이 없음을 의미함

▼ Corollary

$$Z = g(Y) \implies I(X; Y) \geq I(X; g(Y))$$

pf: $X \longrightarrow Y \longrightarrow g(Y)$

$Y \rightarrow g(Y)$ 는 최대 1-1 대응 관계이므로 $g(Y)$ 의 정보는 Y 보다 가질 수 있는 값의 범위가 작음

$\Rightarrow$ trivial!

▼ Corollary

$$X \longrightarrow Y \longrightarrow Z \implies I(X; Y | Z) \leq I(X; Y)$$

pf: Since $I(X; Y, Z) = I(X; Y) + I(X; Z | Y) = I(X; Y)$

and $I(X; Y, Z) = I(X; Z) + I(X; Y | Z),$

$$\Rightarrow I(X; Y) = I(X; Z) + I(X; Y | Z) \geq I(X; Y | Z) \quad \because I(X; Z) \geq 0$$



$$X \longrightarrow Y \longrightarrow Z$$

The dependency of X and Y is decreased (or unchanged) by the observation of a downstream (to receiver) R.V. Z

i.e., $I(X; Y) \geq I(X; Y | Z)$

▼ ex

case1) X_1, X_2, X_3 : independent R.V.s

case2) X_1 : dice $\{1, 2, \dots, 6\}$, X_2 : biased coin $\{0, 1\}$, $X_3 = 2X_2 - 1$

X_1	1	...	6	X_2	0	1
$P(X_1)$	1/6		1/6	$P(X_2)$	$1 - \theta$	θ

$$\theta := \frac{1}{X_1} \in \left\{1, \frac{1}{2}, \frac{1}{3}, \dots, \frac{1}{6}\right\}$$

$$X_1 = 2 \Rightarrow \text{fair coin toss}$$

Which case is a Markov chain as $X \longrightarrow Y \longrightarrow Z$?

Definition : $p(x, y, z) = p(x)p(y|x)p(z|y)$

and we can lead $P(Z|Y)P(X|Y) = P(X, Z | Y)$

$\Rightarrow$ given Y , X and Z are independent from Markov chain

case1) and case2) are both satisfied the definition of Markov chain

case1) $P(X_1)P(X_3) = P(X_1, X_3), P(X_1, X_3 | X_2) = P(X_1|X_2)P(X_3|X_2)$

case2) $X \longrightarrow Y \longrightarrow g(Y)$ 형태이면 Markov chain

X_2 depends X_1 , X_3 is determined by X_2 .

따라서 X_3 는 X_1 에 depend하지만, X_2 를 통해서 영향을 받음

(X_1 은 X_2 를 통해서가 아닌 방법으로 X_3 에 영향을 줄 수 없음)

Caution!

$$I(X; Y | Z) > I(X; Y) \text{ but } I(X; Y | Z) \neq I(X; Y) \text{ is possible}$$

▼ ex: X, Y are fair coin tosses (independent)

$$Z := X + Y \quad \text{--- Not Markov chain}$$

X	0	1
$P(X)$	1/2	1/2

Y	0	1
$P(Y)$	1/2	1/2

$X \setminus Y$	0	1	$P(X)$
0	1/4	1/4	1/2
1	1/4	1/4	1/2
$P(Y)$	1/2	1/2	

$X, Y \setminus Z$	0	1	2	$P(X, Y)$
0, 0	1/4	0	0	1/2
0, 1	0	1/4	0	1/2
1, 0	0	1/4	0	1/4
1, 1	0	0	1/4	1/4
$P(Z)$	1/4	1/2	1/4	

X	0	1
$P(X Z = 1)$	1/2	1/2



- $I(X; Y) = 0$ since X, Y are independent
- $I(X; Y | Z) = H(X|Z) - H(X|Y, Z)$
- $H(X|Y, Z) = 0$ since given $Y, Z, X = Z - Y$ determined

$$\begin{aligned}
 I(X; Y | Z) &= H(X|Z) \\
 &= P(Z=0)H(X|Z=0) \rightarrow P(X=0)=1 \quad (X=0, Y=0) \\
 &\quad + P(Z=1)H(X|Z=1) \\
 &\quad + P(Z=2)H(X|Z=2) \rightarrow P(X=1)=1 \quad (X=1, Y=1) \\
 &= P(Z=1)H(X|Z=1) = \frac{1}{2}H\left(\frac{1}{2}, \frac{1}{2}\right) = 1/2
 \end{aligned}$$

즉, $I(X; Y) = 0 < I(X; Y | Z) = 1/2$

Markov chain이면 부등호가 반대여야 하므로 $X \rightarrow Y \rightarrow Z$ 는 Markov chain이 아님

Sufficient Statistics

▼ Given $\theta \rightarrow X \rightarrow T(X)$, if $I(\theta; T(X)) = I(\theta; X)$, then $T(X)$ is called sufficient for θ .

▼ $\{f_\theta(x)\}$: family of p.m.p.f. indexed by θ ; 1-parameter family

θ 가 결정되면 f 가 결정되고 x 에 의한 값을 얻을 수 있는 확률 질량 함수

(θ : index parameter, θ 에 대하여 확률적인 부분이 있다면 R.V.)


→ parameter 하나가 결정되면 함수의 변수 X 의 확률 분포를 알 수 있음

ex:

X	0	1
$P(X)$	$1 - \theta$	θ

$P(X=1) = \theta$

$X \sim f_\theta(x)$: X is a R.V. from a distribution in this family $\{f_\theta(x)\}$



coin마다 θ 가 정해져 있음

$$\begin{aligned}
 \{f_\theta(x)\} &\rightarrow f_\theta(x) \rightarrow X \\
 \text{family} &\rightarrow \text{p.m.f.} \rightarrow \text{R.V.}
 \end{aligned}$$

$X \rightarrow T(X)$: statistic, X 로부터 얻은 통계량, function of X

Then, $\theta, X, T(X)$ form a Markov chain. i.e., $\theta \rightarrow X \rightarrow T(X)$

$$\Rightarrow \theta \rightarrow X \rightarrow T(X) \implies I(\theta; T(X)) \leq I(\theta; X)$$

If $I(\theta; T(X)) = I(\theta; X)$, then $T(X)$ is called sufficient for θ .



실험 데이터를 해석할 때,

▼ 실험 대상이 family로부터 실험 대상을 거쳐 실험 데이터를 얻기까지

ex: 현실에서 실험을 수행하면 family에 대한 정보는 알 수 없고 실험 결과만 알 수 있음

동전을 10번 던져서 8번이 H가 나오면,

H가 나올 확률이 $\theta = 4/5$ 인 동전을 사용했다고 추정하는 것이 타당함.

물론 실제로 사용한 동전이 H가 4/5의 확률로 나오는 동전인지는 알 수 없음

H가 나올 확률이 1/3인데 던지는 방식에 의해 H만 나왔을 수도 있음

이렇듯 n 번의 시행으로부터 얻은 데이터에서 $T(X)$ 를 구하고

개별 시행의 결과는 시행 할 때마다 다르겠지만 $T(X)$ 를 통해 n 번 중 H가 나오는 횟수의 기대값 θ 를 추정할 수 있다고 요약 가능함

⇒ sufficient statistics

= 통계량을 잘 잡으면 몇 회의 시행이 있었는지,

몇 번 원하는 결과가 나왔는지 모르더라도 θ 를 추정할 수 있음

information loss가 하나도 없음을 보이기 위한 가정으로 쓰임

▼ Def

• Informal version

Informally, $T(X)$ is called sufficient for θ if it contains all information in X about θ .

즉, θ 에 대해서 X 가 가지고 있는 information을 $T(X)$ 가 모두 가지고 있음

• 1st formal version

$T(X)$ is said to be a sufficient statistic relative to $\{f_\theta(x)\}$

if X is independent of θ given $T(X)$ for any distribution $f_\theta(x)$.

즉, $T(X)$ 를 알고 있을 때 X 와 θ 가 indepent함

▼ X 와 θ 의 depend한 정보는 모두 $T(X)$ 에 속해있음

X 와 θ 는 독립이 아님 $\Rightarrow X$ 와 θ 가 독립이면 서로의 정보를 가지고 있지 않음
(직관적으로 독립이면 서로 무관하기 때문에 영향을 주고 받고를 따질 의미가 없어 보임)

주어진 $T(X)$ 에 대해서 알고 있을 때 X 와 θ 가 독립이라는 말은
 X 와 θ 가 주고받는 정보를 $T(X)$ 가 모두 가져갔음을 의미함

$\Rightarrow T(X)$ 에 속한 X, θ 의 정보를 제외하면 X 와 θ 는 독립임

• 2nd formal version

If $\theta \longrightarrow X \longrightarrow T(X)$ is Markov chain then $\theta \longrightarrow T(X) \longrightarrow X$

▼ $T(X)$ 가 θ 와 X 를 연결해주는 모든 정보를 가지고 있음

$\Leftrightarrow \theta$ 와 X 를 연결해주는 $T(X)$ 가 주어지면 X 와 θ 가 indepent함

$\Leftrightarrow T(X)$ 를 알고 있을 때 X 와 θ 가 indepent함



If $T(X)$ is a sufficient statistic, $I(\theta; T(X)) = I(\theta; X)$

▼ i.e., No information loss

2nd formal version definition shows that $I(\theta; T(X)) \geq I(\theta; X)$.

And in general, $\theta \longrightarrow X \longrightarrow T(X)$ then $I(\theta; T(X)) \leq I(\theta; X)$.

Therefore, if $T(X)$ is a sufficient statistic, $I(\theta; T(X)) = I(\theta; X)$.



Where $X_1, \dots, X_n \sim f_\theta(x)$, $Y := g(X_1, \dots, X_n)$ is sufficient for θ

▼ if $P(X_1 = x_1, \dots, X_n = x_n | Y = y)$ does not depend on θ .

Let $X_1, \dots, X_n$ be R.V.s from a p.m.f. with parameter θ

i.e., $X_1, \dots, X_n \sim f_\theta(x)$

and $Y := g(X_1, \dots, X_n)$ is a funtion of $X_1, \dots, X_n$

i.e., Y is deterministic for $X_1, \dots, X_n$

Then Y is sufficient for θ ,

if the conditional probability $P(X_1 = x_1, \dots, X_n = x_n | Y = y)$

does not depend on θ .

Since $Y = g(X_1, \dots, X_n)$, $\theta \longrightarrow Y \longrightarrow (X_1, \dots, X_n)$.

$\Rightarrow P(X_1 = x_1, \dots, X_n = x_n | Y = y)$

$= P(X_1 = x_1, \dots, X_n = x_n | Y = y, \Theta = \theta)$

즉, 주어진 Y 에 대하여 θ 와 $(X_1, \dots, X_n)$ 가 independent.

▼ ex. Bernoulli distribution

X	0	1
$P(X)$	$1 - \theta$	θ

For sample space χ , $x \in \chi = \{0, 1\}$.

$$P_\theta(X = x) = \begin{cases} \theta & x = 1 \\ 1 - \theta & x = 0 \end{cases} \quad (\text{p.m.f.})$$
$$= \theta^x (1 - \theta)^{1-x}$$

Let $X_1, \dots, X_n$ be R.V.s sample from a Bernoulli distribution with θ .

Bernoulli : i.i.d.(independent and identically distributed)

$$\begin{aligned} \text{i.e., } P(X_1 = x_1, \dots, X_n = x_n) &= P(X_1 = x_1) \cdots P(X_n = x_n) \\ &= \theta^{x_1} (1 - \theta)^{1-x_1} \cdots \theta^{x_n} (1 - \theta)^{1-x_n} \\ &= \prod_{i=1}^n \theta^{x_i} (1 - \theta)^{1-x_i} \end{aligned}$$

Introduce a statistic $Y := T(X_1, \dots, X_n) = \sum_{i=1}^n X_i$.

$\Rightarrow$ counting 1's out of $x_1, \dots, x_n \Leftrightarrow$ counting the number of Heads in n tosses

$Y \sim B(n, \theta)$: Binomial ditribution

$$\Rightarrow P(Y = k) = \binom{n}{k} \theta^k (1 - \theta)^{n-k}$$

Consider the conditional probabiltiy

$$\begin{aligned} P(X_1 = x_1, \dots, X_n = x_n) &= \frac{P(X_1=x_1, \dots, X_n=x_n \text{ and } Y=k)}{P(Y=k)} \\ &= \frac{\prod_{i=1}^n \theta^{x_i} (1-\theta)^{1-x_i}}{\binom{n}{k} \theta^k (1-\theta)^{n-k}} \quad \text{where } \sum_{i=1}^n x_i = k \\ &= \frac{\theta^{\sum x_i} (1-\theta)^{n-\sum x_i}}{\binom{n}{k} \theta^k (1-\theta)^{n-k}} \end{aligned}$$

$$= \frac{\theta^k (1-\theta)^{n-k}}{\binom{n}{k} \theta^k (1-\theta)^{n-k}}$$

$$= \frac{1}{\binom{n}{k}}$$

$$\Rightarrow P(X_1 = x_1, \dots, X_n = x_n) = \frac{1}{\binom{n}{k}} \text{ does not depend on } \theta,$$

which means that given $Y = k (= \sum_{i=1}^n x_i)$,

the individual values of the x_i 's cannot provide additional information about θ .

즉, Y 값이 주어지면 x_i 각 값은 (각 x_i 가 0인지 1인지는) θ 에 대한 추가적인 정보를 제공하지 않음

▼ ex. Poisson distribution

p.m.f. $p(k) = \frac{\lambda^k e^{-\lambda}}{k!}$ for $k = 0, 1, 2, \dots$ (λ 를 알면 모든 parameter가 결정됨)

Let $X_1, \dots, X_n$ be sample from a Poisson distribution with λ and $Y = \sum_{i=1}^n X_i$ (=통계량)

※ r : average rate of the event

t : time interval ($\lambda = rt$: 주어진 시간 t 동안 event가 발생하는 횟수의 평균, 빈도)

$$\Rightarrow P(k \text{ events in interval } t) = \frac{(rt)^k e^{-rt}}{k!}$$

$$Y = \sum_{i=1}^n X_i \sim \text{Poisson dist with } \lambda y = n\lambda$$

▼ Y is sufficient for λ .

Consider the conditional probability

$$P(X_1 = x_1, \dots, X_n = x_n | Y = y) = \frac{P(X_1=x_1, \dots, X_n=x_n \text{ and } Y=y)}{P(Y=y)}$$

$$= \frac{P(X_1=x_1, \dots, X_n=x_n)}{P(Y=y)} \quad \text{where } \sum x_i = y$$

(note that $\sum x_i \neq y \Rightarrow P(*) = 0$)

$$= \frac{\prod_{i=1}^n \frac{\lambda^{x_i} e^{-\lambda}}{x_i!}}{\frac{(n\lambda)^y e^{-n\lambda}}{y!}}$$

$$= \frac{\lambda^{x_1 + \dots + x_n} e^{-\lambda}}{\frac{x_1! x_2! \dots x_n!}{(n\lambda)^y e^{-n\lambda}}}$$

$$= \frac{\lambda^y e^{-\lambda}}{\frac{x_1! \dots x_n!}{(n\lambda)^y e^{-n\lambda}}}$$

$$= \frac{y!}{n^y x_1! \dots x_n!} \quad \text{does not depend on } \lambda.$$

▼ Thm: Factorization Theorem

$Y = g(X_1, \dots, X_n)$ is sufficient for θ

$$\iff P(x_1, \dots, x_n | \theta) = \phi(g(x_1, \dots, x_n) | \theta) h(x_1, \dots, x_n)$$

Let $X_1, \dots, X_n$ be i.i.d. R.V.s from p.m.f. $f_\theta(x) \in \{f_\theta(x)\}$,

$Y = g(X_1, \dots, X_n)$ is sufficient for θ

$$\iff P(x_1, \dots, x_n | \theta) = \phi(g(x_1, \dots, x_n) | \theta) h(x_1, \dots, x_n)$$

where ϕ depends on x_i 's only through g (i.e., Y) and h does not depend on θ .

θ 가 주어졌을 때 각 X_i 가 값 x_i 를 가질 확률에 대하여

θ 에 의존하는 값들의 확률은 ϕ , 즉 $g(x_1, \dots, x_n) = Y$ 에 몰려있음 (h 는 θ 에 independent)

$\Rightarrow Y$ 로 표현하지 않는 값들은 θ 에 의존하지 않음

▼ Remark

💡 $P(x_1, \dots, x_n) := P(X_1 = x_1, \dots, X_n = x_n)$
 $P(X_1, \dots, X_n)$ 가 $x_1, \dots, x_n$ 을 어떻게 결정하느냐에 따라 달라짐을 반영한 표기임

💡 $P(*; \theta) = P(*|\theta)$ 이기 위해서는 θ 가 R.V.여야 함
우항의 표기를 사용하고 싶지만, θ 의 분포를 고려하고 싶지 않음
좌항의 θ 는 determined θ 또는 fixed θ , indexed by θ 이고
우항의 θ 는 p.m.f.를 갖는 R.V.임

▼ ex: For Bernoulli distribution,

$$P(x_1, \dots, x_n ; \theta) = \prod_{i=1}^n \theta^{x_i} (1 - \theta)^{1-x_i} = \theta^{\sum x_i} (1 - \theta)^{n - \sum x_i}$$

Let $y = \sum_{i=1}^n x_i$,

$$\theta^{\sum x_i} (1 - \theta)^{n - \sum x_i} = \theta^y (1 - \theta)^{n-y} \times 1 := \phi(y; \theta) \times h(x_1, \dots, x_n)$$

⇒ Bernoulli distribution에 대하여

$P(x_1, \dots, x_n; \theta) = \phi(y; \theta) \times h(x_1, \dots, x_n)$ 를 만족하므로

$Y = \sum X_i$ 는 θ 에 대하여 sufficient statistic임

▼ ex: For Poisson distribution,

$$p(x_1, \dots, x_n; \lambda) = \frac{\lambda^{x_1 + \dots + x_n} e^{-n\lambda}}{x_1! \cdots x_n!} = \lambda^y e^{-n\lambda} \times \frac{1}{x_1! \cdots x_n!}$$

⇒ Poisson distribution에 대하여

$P(x_1, \dots, x_n; \lambda) = \phi(y; \lambda) \times h(x_1, \dots, x_n)$ 를 만족하므로

$Y = \sum X_i$ 는 λ 에 대하여 sufficient statistic임

Minimal sufficient statistic

Def: $T(X)$ is a minimal sufficient statistic relative to $\{f_\theta(x)\}$

if it is a function of every other sufficient statistic U .

즉, sufficient statistic이면서 다른 sufficient statistic로 표시되는 함수

$$\theta \longrightarrow T(X) \longrightarrow U(X) \longrightarrow X$$



A minimal sufficient statistic maximally compresses the information about θ in the sample.
Other sufficient statistics may contain additional irrelevant information.

▼ ex

- $Y = X_1 + \dots + X_n$ is minimal sufficient statistic for θ in the independent coin toss example.

Let $Y_{odd} = X_1 + X_3 + \dots + X_{2n-1}$, $Y_{even} = X_2 + X_4 + \dots + X_{2n}$ and

$\widetilde{Y} = (Y_{odd}, Y_{even})$, then $\widetilde{Y}$ is a sufficient statistic

$$Y = g(\widetilde{Y}) = g(Y_{odd}, Y_{even}) = Y_{odd} + Y_{even}$$

⇒ Y 와 비교할 때, $Y_{odd} + Y_{even}$ 는 불필요하게 세부적으로 나뉜 함수임

- 학교에서 전교 수학점수 평균을 알길 바랄 때,
 - 전체 데이터로부터 각 반의 평균 점수를 구하고 이것들을 모아서 다시 전체 평균을 구하는 것보다
 - 전체 데이터로부터 한 번에 전체 평균을 구하는 것이 훨씬 효율적임
(반 평균이라는 불필요한 정보가 포함되지 않음)